

Ketika Akurasi Tinggi Menyesatkan: Audit Dataset, Replikasi, dan Batas Generalisasi pada Deteksi Deepfake Audio

Studi empiris pada Fake-or-Real, In-the-Wild, dan 14 sistem text-to-speech dari 2019 sampai 2026

Kode dan data pendukung: github.com/Tristan-tech-ai/general-AI

Abstrak

Penelitian ini berangkat dari rencana membandingkan empat arsitektur deep learning untuk membedakan suara asli dan suara sintetis pada dataset Fake-or-Real. Dalam pelaksanaannya, audit terhadap 17.870 berkas audio menemukan bahwa dataset tersebut mengandung korelasi semu yang kuat antara riwayat kompresi berkas dan label kelas. Sebanyak 90,7 persen sampel palsu pada data latih berasal dari berkas MP3, sedangkan pada data uji tidak ada satu pun. Akibatnya model belajar mengenali jejak kompresi, bukan jejak sintesis. Dengan arsitektur, data, dan hyperparameter yang identik, pembagian data secara acak menghasilkan akurasi 99,94 persen sementara partisi resmi menghasilkan 50,00 persen. Selisih tersebut sepenuhnya berasal dari protokol pembagian data. Temuan lanjutan menunjukkan bahwa akurasi pada dataset ini berkorelasi negatif dengan kemampuan mendeteksi sistem text-to-speech generasi 2025 sampai 2026, bahwa kegagalan di bawah gangguan noise sebagian besar merupakan kegagalan kalibrasi ambang dan bukan kegagalan pengenalan, dan bahwa model anti-spoofing terbaik yang tersedia publik memiliki spesifisitas nol persen ketika diuji di luar domain latihnya. Sebagai tanggapan, penelitian ini mengusulkan augmentasi band-gain yang menetralkan isyarat level energi pita tinggi tanpa merusak struktur halusny, dan menguji dampaknya secara terkontrol. Perbandingan setara pada matriks dua kali dua menunjukkan bahwa metodologi yang diperbaiki menyusutkan selisih hasil antar protokol dari 44 sampai 48 poin persentase menjadi 1,13 poin, sehingga hasilnya praktis tidak lagi bergantung pada cara data dibagi.

1. Latar Belakang dan Pertanyaan Penelitian

Deteksi suara sintetis lazim dievaluasi dengan melaporkan akurasi atau equal error rate pada satu dataset. Praktik ini mengandaikan bahwa angka yang tinggi pada dataset uji mencerminkan kemampuan yang tinggi pada kondisi nyata. Penelitian ini menguji andaian tersebut secara langsung.

Tiga pertanyaan dijawab. Pertama, apakah akurasi tinggi pada Fake-or-Real benar-benar mencerminkan kemampuan mendeteksi sintesis. Kedua, bagaimana kinerja model ketika audio terdegradasi oleh noise lingkungan, dan apakah penurunannya berasal dari hilangnya daya pisah atau dari sebab lain. Ketiga, apakah detektor yang dilatih pada sistem text-to-speech lama masih mengenali sistem komersial terbaru yang secara pendengaran sulit dibedakan dari suara manusia.

2. Data dan Metode

2.1 Dataset

Dataset	Isi	Peran
Fake-or-Real (for-2sec)	17.870 klip 2 detik, 16 kHz, seimbang	latih dan uji utama
Fake-or-Real (for-rerec)	816 klip uji, diputar ulang di ruangan	uji lintas kondisi rekaman
In-the-Wild	31.779 klip, 54 pembicara publik	uji lintas korpus
MLAAD	14.000 klip dari 14 sistem TTS, 2019 sampai 2026	uji lintas generasi
DEMAND	6 lingkungan noise nyata, 16 kHz	noise uji, terpisah dari noise latih

Korpus noise untuk pengujian sengaja dipilih dari sumber yang berbeda dengan noise pelatihan. Beberapa korpus yang lazim dipakai bersama, seperti MUSAN, ESC-50, dan FSD50K, sama-sama bersumber dari Freesound, sehingga klaim noise yang belum pernah dilihat tidak selalu terpenuhi. DEMAND direkam sendiri oleh penyusunnya dan karena itu benar-benar independen.

2.2 Arsitektur

Enam arsitektur diuji. Empat berasal dari rencana awal, yaitu Wav2Vec2 Base, Audio Spectrogram Transformer, HuBERT Large, dan CNN-LSTM. Dua ditambahkan selama penelitian, yaitu WavLM Large yang pra-pelatihannya menyertakan denoising, dan Nes2Net-X yang merupakan arsitektur anti-spoofing terbaru dengan back-end 511 ribu parameter. Untuk model berbasis self-supervised, seluruh hidden state diagregasi dengan bobot yang dipelajari, bukan hanya lapisan terakhir seperti pada implementasi aslinya.

2.3 Protokol evaluasi


Metrik yang dilaporkan mencakup akurasi, equal error rate, dan area under curve. Ambang keputusan tidak dipatok pada 0,5 melainkan disesuaikan dengan prior kelas yang diketahui, dan tidak menggunakan label data uji. Untuk perbandingan lintas generasi text-to-speech, seluruh model dikalibrasi terlebih dahulu agar spesifisitasnya 95 persen pada himpunan audio asli yang terpisah, baru kemudian recall diukur. Tanpa langkah ini, detektor yang selalu menjawab palsu akan mencatat recall sempurna.

3. Hasil

3.1 Protokol pembagian data menentukan hasil

Eksperimen pertama menggunakan model, data, dan hyperparameter yang sama persis, dan hanya mengubah cara data dibagi. Hasilnya sangat berbeda.

Skema pembagian data	Akurasi (persen)	EER (persen)	Jumlah berkas uji
Acak 60/20/20	99.75	0.03	3574
Partisi resmi	71.88	28.12	1088



Gambar 1. Akurasi pada dua protokol pembagian data. Arsitektur, data, dan hyperparameter identik.

3.2 Penyebabnya adalah artefak kompresi, dan terukur

Audit terhadap seluruh berkas menemukan bahwa nama berkas kelas palsu mengandung penanda mp3 sedangkan kelas asli tidak. Pemeriksaan spektral mengonfirmasi akibatnya. Energi pada pita di atas 6 kHz untuk kelas asli adalah 0,0336, sedangkan untuk kelas palsu yang berasal dari MP3 hanya 0,0080, yaitu 4,18 kali lebih rendah. Namun untuk 652 sampel palsu yang tidak melalui MP3, selisihnya hanya 1,17 kali. Artinya sebagian besar perbedaan spektral yang tampak berasal dari kompresi, bukan dari sintesis.


Bagian data	Kelas	Asal berkas	Jumlah	Energi di atas 6 kHz
Latih	asli	WAV	6.978	0,0336
Latih	palsu	MP3	6.326	0,0080
Latih	palsu	WAV	652	0,0287
Uji	asli	WAV	544	0,0058
Uji	palsu	WAV	544	0,0043

Sebanyak 90,7 persen sampel palsu pada data latih berasal dari MP3, sedangkan pada data uji tidak ada satu pun. Model yang dilatih pada partisi ini mempelajari aturan bahwa energi frekuensi tinggi yang rendah berarti palsu. Aturan itu benar pada sebagian besar data latih dan sama sekali tidak berlaku pada data uji.

3.3 Ketahanan terhadap noise

Model diuji pada sembilan tingkat signal to noise ratio dengan noise dari korpus yang tidak pernah dilihat selama pelatihan. Temuan utamanya adalah bahwa penurunan akurasi sebagian besar bukan karena model kehilangan daya pisah. Pada 10 dB, WavLM masih memiliki area under curve 0,962, yang berarti pemisahan skornya nyaris utuh, tetapi akurasinya pada ambang tetap hanya 59,8 persen. Mengoreksi ambang saja memulihkan 29,6 poin persentase. Sebaliknya CNN-LSTM gagal dengan cara yang berbeda, yaitu area under curve-nya benar-benar jatuh ke 0,605.

Ketahanan terhadap noise: garis tebal = dilatih dengan augmentasi noise, garis putus = tanpa



Gambar 2. Akurasi dan equal error rate terhadap tingkat noise. Garis tebal adalah model yang dilatih dengan augmentasi noise, garis putus-putus tanpa augmentasi noise.


Perbedaan antara kedua kelompok garis pada Gambar 2 menunjukkan bahwa penurunan yang semula tampak seperti batas fisik sebenarnya adalah celah pelatihan. Model yang dilatih dengan augmentasi noise mempertahankan 95,5 persen akurasi pada 0 dB, yaitu ketika daya noise sama dengan daya sinyal.

3.4 Deteksi lintas generasi text-to-speech

Empat belas sistem text-to-speech diuji, mulai dari Griffin-Lim dan Tacotron2 yang mewakili era dataset, sampai ElevenLabs v3, Chatterbox, OpenAI TTS-1 HD, dan Higgs-Audio-V2 yang mewakili sistem komersial terbaru. Seluruh model dikalibrasi pada spesifisitas 95 persen sebelum recall diukur.

Arsitektur	Augmentasi	n	Akurasi FoR	Recall TTS 2025-2026	Recall TTS 2019 non-MP3
nes2net	full	3	93.75 (5.15)	94.97 (5.34)	82.11 (22.95)
nes2net	fullbgrb	3	97.46 (2.10)	93.67 (3.47)	85.04 (11.54)
nes2net	fullbg	3	97.12 (2.77)	93.50 (4.77)	92.15 (4.19)
wavlm	fullbgrb	3	98.90 (0.18)	92.69 (4.68)	99.33 (0.80)
wavlm	fullbg	3	98.65 (0.37)	92.56 (2.15)	94.26 (9.37)
hubert	fullbg	3	95.71 (1.29)	91.33 (4.04)	58.41 (5.23)
wavlm	full	3	98.62 (0.64)	88.39 (7.29)	97.48 (3.11)
nes2net	fullrb	3	98.50 (0.41)	87.64 (6.41)	60.67 (28.44)
hubert	full	3	95.34 (0.88)	85.67 (6.11)	29.22 (28.96)
nes2net	soft	3	96.75 (0.77)	80.94 (15.78)	66.15 (42.57)

Nilai ditulis sebagai rerata diikuti simpangan baku dalam kurung, dalam persen.




Gambar 3. Recall per sistem text-to-speech pada spesifisitas 95 persen yang disamakan untuk semua model.

3.5 Akurasi in-domain berkorelasi negatif dengan generalisasi

Menggabungkan hasil pada Fake-or-Real dengan hasil pada sistem text-to-speech terbaru menghasilkan pola yang berlawanan dengan harapan. Model dengan akurasi tertinggi pada dataset justru bukan model terbaik pada sistem terbaru. Contoh paling jelas adalah HuBERT dengan augmentasi penuh, yang mencapai akurasi 95,3 persen pada dataset tetapi hanya mengenali 2,3 persen sampel dari sistem text-to-speech 2019 yang tidak dikompresi MP3. Model tersebut pada praktiknya mendeteksi kompresi, bukan sintesis.

Trade-off in-domain vs generalisasi - Nes2Net-X, hanya augmentasi yang berbeda (titik = seed, berlian = rerata)



Gambar 4. Hubungan antara akurasi in-domain dan kemampuan generalisasi untuk beberapa strategi augmentasi pada arsitektur yang sama.

3.6 Model anti-spoofing terbaik runtuh di luar domainnya


Sebuah model anti-spoofing publik dengan equal error rate 1,49 persen pada ASVspoof 2021 diuji tanpa penyesuaian pada Fake-or-Real. Seluruh 544 berkas asli ditandai sebagai palsu, sehingga spesifisitasnya nol persen. Area under curve-nya 0,0233, yang berarti urutan skornya terbalik. Bila polaritas dibalik, nilainya menjadi 0,9767, sehingga model tersebut sebenarnya tetap sangat diskriminatif namun dengan arah keputusan yang keliru pada korpus ini. Metrik equal error rate yang dilaporkan dalam domain tidak dapat menangkap kegagalan semacam ini.

3.7 Apakah rekayasa metodologi benar-benar melampaui baseline

Semua perbandingan sejauh ini menyandingkan konfigurasi proposal pada split acak dengan konfigurasi yang diperbaiki pada partisi resmi. Kedua kolom itu tidak setara, sehingga tidak dapat menjawab pertanyaan pokok, yaitu apakah rekayasa yang dilakukan memang bernilai atau hanya memindahkan angka dari satu protokol ke protokol lain. Untuk menjawabnya, tiap arsitektur dijalankan pada keempat kombinasi dari dua konfigurasi dan dua skema pembagian data, dengan batch, seed, dan data yang dijaga tetap. Dengan demikian setiap perbandingan hanya mengubah satu variabel.

Konfigurasi proposal memakai learning rate 0,001 seragam dengan encoder ikut dilatih, 20 epoch tanpa early stopping, normalisasi amplitudo puncak, augmentasi noise pada rentang 15 sampai 30 dB, dan ambang keputusan 0,5. Konfigurasi yang diperbaiki memakai learning rate per model dengan encoder dibekukan dan agregasi berbobot antar lapisan, 10 epoch dengan early stopping pada equal error rate, normalisasi loudness, augmentasi penuh, dan ambang prior-matched.

Arsitektur	Konfigurasi	Split acak	Partisi resmi	Selisih (pp)
ast	Proposal apa adanya	99.86	51.56	+48.30
	Diperbaiki	99.75	89.15	+10.59
wavlm	Proposal apa adanya	100.00	55.61	+44.39
	Diperbaiki	99.75	98.62 (0.64)	+1.13



Gambar 5. Ketergantungan hasil pada protokol evaluasi. Garis yang landai menandakan hasil yang bertahan ketika domain rekaman berubah. Garis putus-putus abu-abu adalah konfigurasi proposal.

Pada kolom partisi resmi, yaitu satu-satunya kolom yang menguji generalisasi lintas domain, ast naik dari 51.56 menjadi 89.15 persen, yaitu +37.59 poin; wavlm naik dari 55.61 menjadi 98.62 persen, yaitu +43.01 poin. Rerata perbaikan +40.30 poin persentase pada protokol yang sama persis. Pada kolom split acak selisihnya justru sedikit negatif, sehingga bila penelitian ini hanya melaporkan kolom tersebut seluruh rekayasa akan tampak tidak berguna atau bahkan merugikan.

Kolom paling kanan memuat temuan yang menurut penulis paling penting. Angka itu mengukur seberapa jauh hasil sebuah konfigurasi bergantung pada protokol evaluasi yang dipilih. Pada konfigurasi proposal selisihnya 44 sampai 48 poin persentase, yang berarti nilai yang dilaporkan hampir seluruhnya ditentukan oleh cara data dibagi dan bukan oleh kemampuan model. Pada konfigurasi yang diperbaiki dengan WavLM selisihnya menyusut menjadi 1,13 poin. Model tersebut memberikan hasil yang praktis sama pada kedua protokol. Inilah bentuk terukur dari generalisasi yang dituju, yaitu bukan sekadar angka yang

lebih tinggi melainkan angka yang bertahan ketika domain rekamannya berubah.

4. Usulan: Augmentasi Band-Gain

Diagnosis pada bagian 3.2 menunjukkan bahwa dua isyarat berbeda menempati pita frekuensi tinggi yang sama. Yang pertama adalah level energi, yang merupakan jejak kompresi dan harus dinetralkan. Yang kedua adalah struktur halus di dalam pita, yang merupakan jejak vocoder dan justru harus dipertahankan. Augmentasi yang lazim dipakai, seperti penapisan lolos bawah dan RawBoost, menghapus keduanya sekaligus.

Augmentasi band-gain yang diusulkan hanya mengalikan gain acak pada tiap pita di atas 3 kHz. Dengan demikian rasio energi antar pita menjadi tidak informatif terhadap label, sementara bentuk spektrum di dalam pita tetap utuh. Pengukuran memastikan sifat ini. Pada pita 6 sampai 7 kHz, band-gain menyisakan korelasi bentuk 0,89 terhadap sinyal asli dengan energi turun ke 41 persen, sedangkan penapisan lolos bawah menyisakan korelasi negatif 0,05 dengan energi nol persen.

Strategi augmentasi	Akurasi FoR	Recall TTS 2025-2026	Recall TTS 2019 non-MP3
Basis (noise, reverb, codec)	93.75 (5.15)	94.97 (5.34)	82.11 (22.95)
Basis ditambah RawBoost	98.50 (0.41)	87.64 (6.41)	60.67 (28.44)
Basis ditambah band-gain	97.12 (2.77)	93.50 (4.77)	92.15 (4.19)
Basis ditambah keduanya	97.46 (2.10)	93.67 (3.47)	85.04 (11.54)

Nes2Net-X, tiga seed per strategi, arsitektur dan data identik. Rerata diikuti simpangan baku dalam kurung.

Perbandingan tersebut menunjukkan bahwa RawBoost menaikkan akurasi pada dataset tetapi menurunkan kemampuan generalisasi, sedangkan band-gain menaikkan akurasi dengan penurunan generalisasi yang jauh lebih kecil dan bahkan memperbaiki recall pada sistem lama yang tidak dikompresi. Kombinasi keduanya memberi hasil terbaik pada beberapa sumbu sekaligus.

5. Keterbatasan

Beberapa keterbatasan perlu dinyatakan secara jujur. Pertama, sebagian besar konfigurasi hanya diulang dengan tiga inisialisasi acak, sedangkan variasi antar inisialisasi pada pengujian lintas generasi cukup besar, dalam beberapa kasus melebihi lima poin persentase. Kesimpulan mengenai urutan peringkat model karena itu bersifat indikatif.

Kedua, korelasi negatif antara akurasi in-domain dan kemampuan generalisasi dihitung dari tujuh model. Ukuran sampel sekecil itu tidak cukup untuk menyimpulkan besaran korelasinya. Yang menopang temuan ini bukan nilai korelasinya melainkan mekanismenya, yang terdokumentasi secara terpisah melalui audit dataset, eksperimen augmentasi terkontrol, dan pola kebutaan model terhadap sistem yang tidak dikompresi.

Ketiga, efek band-gain berbeda arah pada arsitektur yang berbeda. Penjelasan berdasarkan ruang perbaikan yang tersisa masuk akal namun disusun setelah melihat data, sehingga perlu pengujian pada arsitektur tambahan sebelum dapat dinyatakan sebagai mekanisme umum.

Keempat, sejumlah kesimpulan sementara dalam penelitian ini pernah keliru dan telah dikoreksi setelah pengukuran ulang. Riwayat koreksi tersebut sengaja dipertahankan dalam dokumentasi pendukung agar dapat ditelusuri.

6. Kesimpulan

Akurasi yang tinggi pada satu dataset tidak dengan sendirinya menunjukkan kemampuan mendeteksi suara sintesis. Pada Fake-or-Real, sebagian besar selisih angka yang dilaporkan dapat ditelusuri ke protokol pembagian data dan ke artefak kompresi yang berkorelasi dengan label. Kegagalan di bawah gangguan noise sebagian besar merupakan kegagalan kalibrasi ambang, bukan kegagalan pengenalan,

sehingga dapat dipulihkan tanpa mengubah model. Sistem text-to-speech komersial terbaru masih dapat dideteksi pada tingkat 97 sampai 99 persen dengan tingkat alarm palsu 5 persen, tetapi hanya oleh arsitektur dan strategi augmentasi tertentu, dan bukan oleh model yang menempati peringkat teratas pada dataset.

Pertanyaan apakah seluruh rekayasa metodologi ini bernilai dijawab pada bagian 3.7 dengan perbandingan yang setara. Pada protokol yang sama persis, konfigurasi yang diperbaiki mengungguli konfigurasi proposal dengan selisih puluhan poin persentase. Yang lebih penting, selisih hasil antara kedua protokol menyusut dari 44 sampai 48 poin menjadi hanya 1,13 poin pada konfigurasi terbaik. Nilai sebenarnya dari rekayasa tersebut bukan terletak pada angka yang lebih tinggi, melainkan pada berkurangnya ketergantungan hasil terhadap pilihan protokol evaluasi. Perlu ditegaskan bahwa perbaikan ini sama sekali tidak terlihat bila hasil hanya dilaporkan pada split acak, karena di sana selisihnya justru sedikit negatif.

Implikasi praktisnya adalah bahwa pemilihan model sebaiknya tidak didasarkan pada akurasi dataset tunggal, dan bahwa pelaporan hasil sebaiknya menyertakan spesifisitas pada korpus asing serta simpangan baku atas beberapa inisialisasi.