

Ketika Akurasi Tinggi Menyesatkan: Audit Dataset, Replikasi, dan Batas Generalisasi pada Deteksi Deepfake Audio

Studi empiris pada Fake-or-Real, In-the-Wild, dan 14 sistem text-to-speech dari 2019 sampai 2026

Kode dan data pendukung: github.com/Tristan-tech-ai/general-AI

Abstrak

Penelitian ini berangkat dari rencana membandingkan empat arsitektur deep learning untuk membedakan suara asli dan suara sintetis pada dataset Fake-or-Real. Dalam pelaksanaannya, audit terhadap 17.870 berkas audio menemukan bahwa dataset tersebut mengandung korelasi semu yang kuat antara riwayat kompresi berkas dan label kelas. Sebanyak 90,7 persen sampel palsu pada data latih berasal dari berkas MP3, sedangkan pada data uji tidak ada satu pun. Akibatnya model belajar mengenali jejak kompresi, bukan jejak sintesis. Dengan arsitektur, data, dan hyperparameter yang identik, pembagian data secara acak menghasilkan akurasi 99,94 persen sementara partisi resmi menghasilkan 50,00 persen. Selisih tersebut sepenuhnya berasal dari protokol pembagian data. Temuan lanjutan menunjukkan bahwa akurasi pada dataset ini berkorelasi negatif dengan kemampuan mendeteksi sistem text-to-speech generasi 2025 sampai 2026, bahwa kegagalan di bawah gangguan noise sebagian besar merupakan kegagalan kalibrasi ambang dan bukan kegagalan pengenalan, dan bahwa model anti-spoofing terbaik yang tersedia publik memiliki spesifisitas nol persen ketika diuji di luar domain latihnya. Sebagai tanggapan, penelitian ini mengusulkan augmentasi band-gain yang menetralkan isyarat level energi pita tinggi tanpa merusak struktur halusny, dan menguji dampaknya secara terkontrol. Perbandingan setara antara metodologi proposal dan metodologi yang diperbaiki dilakukan dengan tiga inisialisasi acak per sel, lalu diuji dengan uji t Welch dan dikoreksi Holm-Bonferroni. Dari seluruh perbandingan itu hanya satu keputusan yang terbukti menentukan, yaitu besaran learning rate relatif terhadap ukuran dan jenis encoder. Learning rate seragam 0,001 yang ditetapkan proposal memberi 93.57 persen (1.75) pada AST yang berukuran 86 juta parameter, tetapi menjatuhkan WavLM Large ke 63.73 persen (5.86) dan HuBERT Large ke 52.14 persen (8.08), yaitu mendekati tebakan acak. Seluruh perbandingan lain, termasuk antara membekukan dan melatih encoder, tidak terbukti berbeda setelah ragam antar inisialisasi diperhitungkan.

1. Latar Belakang dan Pertanyaan Penelitian

Deteksi suara sintetis lazim dievaluasi dengan melaporkan akurasi atau equal error rate pada satu dataset. Praktik ini mengandaikan bahwa angka yang tinggi pada dataset uji mencerminkan kemampuan yang tinggi pada kondisi nyata. Penelitian ini menguji andaian tersebut secara langsung.

Tiga pertanyaan dijawab. Pertama, apakah akurasi tinggi pada Fake-or-Real benar-benar mencerminkan kemampuan mendeteksi sintesis. Kedua, bagaimana kinerja model ketika audio terdegradasi oleh noise lingkungan, dan apakah penurunannya berasal dari hilangnya daya pisah atau dari sebab lain. Ketiga, apakah detektor yang dilatih pada sistem text-to-speech lama masih mengenali sistem komersial terbaru yang secara pendengaran sulit dibedakan dari suara manusia.

2. Data dan Metode

2.1 Dataset

Dataset	Isi	Peran
Fake-or-Real (for-2sec)	17.870 klip 2 detik, 16 kHz, seimbang	latih dan uji utama

Dataset	Isi	Peran
Fake-or-Real (for-rerec)	816 klip uji, diputar ulang di ruangan	uji lintas kondisi rekaman
In-the-Wild	31.779 klip, 54 pembicara publik	uji lintas korpus
MLAAD	14.000 klip dari 14 sistem TTS, 2019 sampai 2026	uji lintas generasi
DEMAND	6 lingkungan noise nyata, 16 kHz	noise uji, terpisah dari noise latih

Korpus noise untuk pengujian sengaja dipilih dari sumber yang berbeda dengan noise pelatihan. Beberapa korpus yang lazim dipakai bersama, seperti MUSAN, ESC-50, dan FSD50K, sama-sama bersumber dari Freesound, sehingga klaim noise yang belum pernah dilihat tidak selalu terpenuhi. DEMAND direkam sendiri oleh penyusunnya dan karena itu benar-benar independen.

2.2 Arsitektur

Enam arsitektur diuji. Empat berasal dari rencana awal, yaitu Wav2Vec2 Base, Audio Spectrogram Transformer, HuBERT Large, dan CNN-LSTM. Dua ditambahkan selama penelitian, yaitu WavLM Large yang pra-pelatihannya menyertakan denoising, dan Nes2Net-X yang merupakan arsitektur anti-spoofing terbaru dengan back-end 511 ribu parameter. Untuk model berbasis self-supervised, seluruh hidden state diagregasi dengan bobot yang dipelajari, bukan hanya lapisan terakhir seperti pada implementasi aslinya.

2.3 Protokol evaluasi


Metrik yang dilaporkan mencakup akurasi, equal error rate, dan area under curve. Ambang keputusan tidak dipatok pada 0,5 melainkan disesuaikan dengan prior kelas yang diketahui, dan tidak menggunakan label data uji. Untuk perbandingan lintas generasi text-to-speech, seluruh model dikalibrasi terlebih dahulu agar spesifisitasnya 95 persen pada himpunan audio asli yang terpisah, baru kemudian recall diukur. Tanpa langkah ini, detektor yang selalu menjawab palsu akan mencatat recall sempurna.

3. Hasil

3.1 Protokol pembagian data menentukan hasil

Eksperimen pertama menggunakan model, data, dan hyperparameter yang sama persis, dan hanya mengubah cara data dibagi. Hasilnya sangat berbeda.

Skema pembagian data	Akurasi (persen)	EER (persen)	Jumlah berkas uji
Acak 60/20/20	99.75	0.03	3574
Partisi resmi	71.88	28.12	1088



Gambar 1. Akurasi pada dua protokol pembagian data. Arsitektur, data, dan hyperparameter identik.

Selama penelitian berlangsung, dua kejadian tidak sengaja menyediakan uji yang jauh lebih tajam terhadap protokol pembagian data. Pada kedua kejadian itu sebuah kerusakan besar menimpa model, dan pertanyaannya adalah protokol mana yang mampu mendeteksinya.

Kejadian pertama adalah sebuah bug yang menyebabkan encoder tidak pernah menerima gradien sama sekali, sehingga sebagian terbesar kapasitas model tidak pernah dilatih. Kejadian kedua adalah learning rate seragam yang ditetapkan proposal, yang ketika benar benar diterapkan pada WavLM Large merusak representasi pra-latihnya sampai area under curve turun mendekati tebakan acak. Tabel berikut menunjukkan berapa besar perubahan yang tercatat oleh masing-masing protokol.

Kerusakan pada model	Terdeteksi partisi resmi (pp)	Terdeteksi split acak (pp)	Perubahan AUC resmi	Perubahan AUC acak
Encoder tidak pernah dilatih karena bug	+9.38	-0.06	+0.0680	-0.0000
Encoder rusak karena learning rate terlalu tinggi	-41.18	-0.06	-0.3408	-0.0021

Split acak nyaris tidak bergerak pada kedua kejadian. Model yang encodernya tidak pernah dilatih tetap mencatat akurasi di atas 99 persen, dan model yang representasinya sudah rusak sampai hampir setara tebakan acak pada partisi resmi tetap mencatat 99,52 persen dengan AUC 0,9979 pada split acak. Temuan ini lebih keras daripada pernyataan bahwa split acak menghasilkan angka yang menggelembung. Protokol tersebut ternyata tidak dapat membedakan model yang bekerja dari model yang sebagian besar kapasitasnya mati atau rusak. Angka yang dihasilkannya karena itu tidak dapat dipakai untuk memilih model, membandingkan arsitektur, atau bahkan untuk memastikan bahwa pelatihan berjalan sebagaimana mestinya.

3.2 Penyebabnya adalah artefak kompresi, dan terukur

Audit terhadap seluruh berkas menemukan bahwa nama berkas kelas palsu mengandung penanda mp3 sedangkan kelas asli tidak. Pemeriksaan spektral mengonfirmasi akibatnya. Energi pada pita di atas 6 kHz untuk kelas asli adalah 0,0336, sedangkan untuk kelas palsu yang berasal dari MP3 hanya 0,0080, yaitu 4,18 kali lebih rendah. Namun untuk 652 sampel palsu yang tidak melalui MP3, selisihnya hanya 1,17 kali. Artinya sebagian besar perbedaan spektral yang tampak berasal dari kompresi, bukan dari sintesis.


Bagian data	Kelas	Asal berkas	Jumlah	Energi di atas 6 kHz
Latih	asli	WAV	6.978	0,0336
Latih	palsu	MP3	6.326	0,0080
Latih	palsu	WAV	652	0,0287
Uji	asli	WAV	544	0,0058
Uji	palsu	WAV	544	0,0043

Sebanyak 90,7 persen sampel palsu pada data latih berasal dari MP3, sedangkan pada data uji tidak ada satu pun. Model yang dilatih pada partisi ini mempelajari aturan bahwa energi frekuensi tinggi yang rendah berarti palsu. Aturan itu benar pada sebagian besar data latih dan sama sekali tidak berlaku pada data uji.

3.3 Ketahanan terhadap noise

Model diuji pada sembilan tingkat signal to noise ratio dengan noise dari korpus yang tidak pernah dilihat selama pelatihan. Temuan utamanya adalah bahwa penurunan akurasi sebagian besar bukan karena model kehilangan daya pisah. Pada 10 dB, WavLM masih memiliki area under curve 0,962, yang berarti pemisahan skornya nyaris utuh, tetapi akurasinya pada ambang tetap hanya 59,8 persen. Mengoreksi ambang saja memulihkan 29,6 poin persentase. Sebaliknya CNN-LSTM gagal dengan cara yang berbeda, yaitu area under curve-nya benar-benar jatuh ke 0,605.

Ketahanan terhadap noise: garis tebal = dilatih dengan augmentasi noise, garis putus = tanpa



Gambar 2. Akurasi dan equal error rate terhadap tingkat noise. Garis tebal adalah model yang dilatih dengan augmentasi noise, garis putus-putus tanpa augmentasi noise.


Perbedaan antara kedua kelompok garis pada Gambar 2 menunjukkan bahwa penurunan yang semula tampak seperti batas fisik sebenarnya adalah celah pelatihan. Model yang dilatih dengan augmentasi noise mempertahankan 95,5 persen akurasi pada 0 dB, yaitu ketika daya noise sama dengan daya sinyal.

3.4 Deteksi lintas generasi text-to-speech

Empat belas sistem text-to-speech diuji, mulai dari Griffin-Lim dan Tacotron2 yang mewakili era dataset, sampai ElevenLabs v3, Chatterbox, OpenAI TTS-1 HD, dan Higgs-Audio-V2 yang mewakili sistem komersial terbaru. Seluruh model dikalibrasi pada spesifisitas 95 persen sebelum recall diukur.

Arsitektur	Augmentasi	n	Akurasi FoR	Recall TTS 2025-2026	Recall TTS 2019 non-MP3
nes2net	full	3	93.75 (5.15)	94.97 (5.34)	82.11 (22.95)
nes2net	fullbgrb	3	97.46 (2.10)	93.67 (3.47)	85.04 (11.54)
nes2net	fullbg	3	97.12 (2.77)	93.50 (4.77)	92.15 (4.19)
wavlm	fullbgrb	3	98.90 (0.18)	92.69 (4.68)	99.33 (0.80)
wavlm	fullbg	3	98.65 (0.37)	92.56 (2.15)	94.26 (9.37)
hubert	fullbg	3	95.71 (1.29)	91.33 (4.04)	58.41 (5.23)
wavlm	full	3	98.62 (0.64)	88.39 (7.29)	97.48 (3.11)
nes2net	fullrb	3	98.50 (0.41)	87.64 (6.41)	60.67 (28.44)
hubert	full	3	95.01 (0.97)	85.67 (6.11)	29.22 (28.96)
nes2net	soft	3	96.75 (0.77)	80.94 (15.78)	66.15 (42.57)

Nilai ditulis sebagai rerata diikuti simpangan baku dalam kurung, dalam persen.




Gambar 3. Recall per sistem text-to-speech pada spesifisitas 95 persen yang disamakan untuk semua model.

3.5 Akurasi in-domain berkorelasi negatif dengan generalisasi

Menggabungkan hasil pada Fake-or-Real dengan hasil pada sistem text-to-speech terbaru menghasilkan pola yang berlawanan dengan harapan. Model dengan akurasi tertinggi pada dataset justru bukan model terbaik pada sistem terbaru. Contoh paling jelas adalah HuBERT dengan augmentasi penuh, yang mencapai akurasi 95,3 persen pada dataset tetapi hanya mengenali 2,3 persen sampel dari sistem text-to-speech 2019 yang tidak dikompresi MP3. Model tersebut pada praktiknya mendeteksi kompresi, bukan sintesis.

Trade-off in-domain vs generalisasi - Nes2Net-X, hanya augmentasi yang berbeda (titik = seed, berlian = rerata)



Gambar 4. Hubungan antara akurasi in-domain dan kemampuan generalisasi untuk beberapa strategi augmentasi pada arsitektur yang sama.

3.6 Model anti-spoofing terbaik runtuh di luar domainnya


Sebuah model anti-spoofing publik dengan equal error rate 1,49 persen pada ASVspoof 2021 diuji tanpa penyesuaian pada Fake-or-Real. Seluruh 544 berkas asli ditandai sebagai palsu, sehingga spesifisitasnya nol persen. Area under curve-nya 0,0233, yang berarti urutan skornya terbalik. Bila polaritas dibalik, nilainya menjadi 0,9767, sehingga model tersebut sebenarnya tetap sangat diskriminatif namun dengan arah keputusan yang keliru pada korpus ini. Metrik equal error rate yang dilaporkan dalam domain tidak dapat menangkap kegagalan semacam ini.

3.7 Apakah rekayasa metodologi benar-benar melampaui baseline

Semua perbandingan sejauh ini menyandingkan konfigurasi proposal pada split acak dengan konfigurasi yang diperbaiki pada partisi resmi. Kedua kolom itu tidak setara, sehingga tidak dapat menjawab pertanyaan pokok, yaitu apakah rekayasa yang dilakukan memang bernilai atau hanya memindahkan angka dari satu protokol ke protokol lain. Untuk menjawabnya, tiap arsitektur dijalankan pada keempat kombinasi dari dua konfigurasi dan dua skema pembagian data, dengan batch, seed, dan data yang dijaga tetap. Dengan demikian setiap perbandingan hanya mengubah satu variabel.

Konfigurasi proposal memakai learning rate 0,001 seragam dengan encoder ikut dilatih, 20 epoch tanpa early stopping, normalisasi amplitudo puncak, augmentasi noise pada rentang 15 sampai 30 dB, dan ambang keputusan 0,5. Konfigurasi yang diperbaiki memakai learning rate per model dengan encoder dibekukan dan agregasi berbobot antar lapisan, 10 epoch dengan early stopping pada equal error rate, normalisasi loudness, augmentasi penuh, dan ambang prior-matched.

Arsitektur	Konfigurasi	Split acak	Partisi resmi	Selisih (pp)
ast	Proposal apa adanya	99.69	74.85 (1.47)	+24.85
	Diperbaiki	99.75	89.15 (3.49)	+10.59
wavlm	Proposal apa adanya	99.52	54.41 (4.96)	+45.11
	Diperbaiki	99.75	98.62 (0.64)	+1.13



Gambar 5. Ketergantungan hasil pada protokol evaluasi. Garis yang landai menandakan hasil yang bertahan ketika domain rekaman berubah. Garis putus-putus abu-abu adalah konfigurasi proposal.

Pada kolom partisi resmi, yaitu satu-satunya kolom yang menguji generalisasi lintas domain, ast naik dari 74.85 menjadi 89.15 persen, yaitu +14.31 poin; wavlm naik dari 54.41 menjadi 98.62 persen, yaitu +44.21 poin. Rerata perbaikan +29.26 poin persentase pada protokol yang sama persis. Pada kolom split acak selisihnya justru sedikit negatif, sehingga bila penelitian ini hanya melaporkan kolom tersebut seluruh rekayasa akan tampak tidak berguna atau bahkan merugikan.

Kolom paling kanan mengukur seberapa jauh hasil sebuah konfigurasi bergantung pada protokol evaluasi yang dipilih. Selisih yang besar berarti nilai yang dilaporkan lebih banyak ditentukan oleh cara data dibagi daripada oleh kemampuan model. Selisih yang kecil berarti sebaliknya, dan itulah bentuk terukur dari generalisasi yang dituju, yaitu bukan sekadar angka yang lebih tinggi melainkan angka yang bertahan ketika domain rekamannya berubah.

Tabel ini perlu dibaca dengan hati-hati dan tidak boleh berdiri sendiri. Tiap konfigurasi dievaluasi pada ambang keputusannya masing-masing, yaitu 0,5 untuk proposal dan prior-matched untuk versi diperbaiki, karena penetapan ambang termasuk bagian dari metodologi yang dibandingkan. Akibatnya selisih pada kolom partisi resmi mencampur dua sumber sekaligus. Dua bagian berikutnya memisahkan sumber-sumber tersebut, dan hasilnya membalik sebagian kesimpulan yang tampak dari tabel ini.

3.8 Pemecahan lanjutan: sumbangan ambang dan sumbangan pelatihan

Angka pada bagian sebelumnya membandingkan dua metodologi secara utuh. Di dalamnya dua hal berubah bersamaan, yaitu cara model dilatih dan cara ambang keputusan ditetapkan. Selisih tersebut karena itu tidak boleh dibaca sebagai sumbangan pelatihan semata. Untuk memisahkannya, empat besaran dihitung dari berkas skor yang sama persis tanpa melatih ulang apa pun, yaitu tiap konfigurasi dievaluasi pada kedua ambang.

Arsitektur	Proposal, ambang 0,5	Proposal, ambang prior	Rekayasa, ambang 0,5	Rekayasa, ambang prior
ast	74.85	93.57	58.82	89.15
wavlm	54.41	63.73	83.15	98.62

Arsitektur	Sumbangan ambang saja (pp)	Sumbangan pelatihan saja (pp)	AUC proposal	AUC rekayasa	EER proposal	EER rekayasa
ast	+18.72	-16.02	0.9824	0.9540	6.50	10.81
wavlm	+9.31	+28.74	0.7205	0.9992	36.31	1.41

Pemecahan ini membalik sebagian kesimpulan pada bagian sebelumnya, dan arahnya berbeda pada tiap arsitektur. Pada AST, sumbangan pelatihan bertanda negatif. Konfigurasi proposal yang dievaluasi pada ambang prior-matched mencapai 93.57 persen (1.75), sedangkan konfigurasi yang direkayasa dengan encoder dibekukan hanya mencapai 89.15 persen (3.49). Area under curve juga lebih rendah, yaitu 0.9540 lawan 0.9824, sehingga penurunan itu bukan sekadar soal letak ambang melainkan penurunan daya pisah yang sesungguhnya.

Pada WavLM Large keadaannya justru sebaliknya dan jauh lebih ekstrem. Konfigurasi proposal runtuh menjadi 63.73 persen (5.86) dengan area under curve 0.7205 dan equal error rate 36.31 persen, yaitu hanya sedikit lebih baik daripada menebak. Konfigurasi yang direkayasa mencapai 98.62 persen (0.64) dengan area under curve 0.9992 dan equal error rate 1.41 persen. Di sini paket rekayasa bukan hanya menolong, melainkan menjadi pembeda antara model yang berguna dan model yang tidak.


Dua arah yang berlawanan pada dua arsitektur menunjukkan bahwa pertanyaan mana metodologi yang lebih baik tidak memiliki jawaban tunggal. Penyebabnya dapat ditunjuk secara tepat, dan itu dibahas pada bagian 3.9 dan 3.10.

3.9 Perbaikan mana yang membeli berapa

Bagian sebelumnya menunjukkan bahwa metodologi yang diperbaiki mengungguli konfigurasi proposal, dan bahwa sebagian besar selisihnya berasal dari kalibrasi. Yang belum terjawab adalah perbaikan mana di dalam paket itu yang benar-benar menyumbang. Untuk menjawabnya, perbaikan ditambahkan satu per satu di atas konfigurasi proposal, seluruhnya pada AST, partisi resmi, batch 32, dan seed 42. Akurasi dilaporkan pada ambang prior-matched untuk semua langkah agar sumbu ambang tidak ikut bercampur.

Langkah	Perbaikan yang ditambahkan	n	Akurasi	Selisih	p mentah	p Holm	AUC
L1	Konfigurasi proposal apa adanya	3	93.57 (1.75)				0.9824
L2	Normalisasi loudness menggantikan peak	3	90.50 (1.75)	-3.06	0.099	0.197	0.9688

Langka h	Perbaikan yang ditambahkan	n	Akurasi	Selisih	p mentah	p Holm	AUC
L3	Learning rate per model dan encoder dibekukan	3	74.26 (3.27)	-16.24	0.004	0.018	0.8256
L4	Early stopping pada equal error rate	2	85.39 (1.43)	+11.12	0.016	0.047	0.9277
L5	Augmentasi penuh menggantikan noise saja	3	89.15 (3.49)	+3.77	0.201	0.201	0.9540



Gambar 6. Sumbangan tiap perbaikan pada AST di partisi resmi. Batang merah menandai perbaikan yang merugikan bila berdiri sendiri.

Tangga ini menjawab pertanyaan yang tertinggal pada bagian 3.8, meskipun jawabannya lebih lemah daripada yang diharapkan. Sepanjang lima langkah, akurasi justru turun, sehingga paket rekayasa secara keseluruhan merugikan pada arsitektur ini. Langkah dengan selisih terbesar adalah pembekuan encoder, diikuti early stopping pada arah sebaliknya, sedangkan normalisasi loudness dan augmentasi penuh memberi selisih yang jauh lebih kecil.

Selisih tiap langkah diuji terhadap langkah sebelumnya dengan uji t Welch dan dikoreksi Holm-Bonferroni untuk empat pengujian sekaligus. Dua langkah dengan selisih terbesar memiliki nilai p mentah di bawah 0,05, tetapi tidak satu pun bertahan di bawah ambang setelah koreksi. Sebabnya perlu dinyatakan dengan tepat. Seluruh tangga ini dijalankan pada AST, yaitu arsitektur dengan ragam antar inisialisasi terbesar di antara yang diuji dalam penelitian ini, sehingga daya ujinya paling rendah justru di tempat yang paling banyak dibandingkan. Nilai p yang besar di sini menunjukkan kurangnya bukti, bukan ketiadaan efek.

Kesimpulan yang dapat dipertanggungjawabkan dari tangga ini karena itu terbatas. Arah tiap langkah konsisten dengan penjelasan mekanistik yang diajukan pada bagian 3.10, tetapi besarannya belum dapat dipisahkan dari ragam pada ukuran sampel ini. Tangga ablasi lebih tepat dibaca sebagai peta kemungkinan sebab yang menunjukkan ke mana harus mencari, bukan sebagai pengukuran sumbangan tiap perbaikan. Versi awal naskah ini menyajikannya sebagai pengukuran, dan itu keliru.

Perlu dicatat bahwa versi tangga ini berbeda jauh dari versi yang sempat disusun lebih awal dalam penelitian. Pada versi awal, titik tolaknya adalah konfigurasi proposal yang encodernya tidak pernah benar-benar dilatih karena sebuah bug, sehingga normalisasi loudness tampak merugikan 7,81 poin dan pembekuan encoder tampak tidak berpengaruh sama sekali. Kedua kesan itu keliru dan telah dikoreksi setelah bug diperbaiki. Riwayat koreksinya dipertahankan dalam dokumentasi pendukung karena bug

tersebut justru ditemukan lewat tangga ablasi ini, yaitu ketika dua langkah yang seharusnya berbeda menghasilkan skor yang identik sampai empat desimal.

3.10 Tidak ada satu perlakuan encoder yang benar untuk semua arsitektur

Bagian 3.9 menunjukkan bahwa membekukan encoder merupakan sumber kerugian terbesar pada AST. Bagian 3.8 menunjukkan bahwa pada WavLM Large paket rekayasa yang sama justru menyelamatkan model dari keruntuhan. Kedua pernyataan itu tampak bertentangan, dan matriks berikut menjelaskan mengapa keduanya benar sekaligus.

Tiga baris pertama pada tiap arsitektur memakai paket rekayasa yang sama persis, yaitu 10 epoch dengan early stopping, augmentasi penuh, normalisasi loudness, dan agregasi berbobot antar lapisan. Hanya perlakuan encoder yang berbeda, sehingga perbandingan di antara ketiganya bersifat satu variabel. Baris keempat disertakan sebagai acuan, yaitu konfigurasi proposal apa adanya.

AST, 86 juta parameter, pra-latih terselia


Perlakuan encoder	n	Akurasi	AUC	EER
Encoder dibekukan	3	89.15 (3.49)	0.9540	10.81
Encoder dilatih, laju wajar per model	3	93.38 (1.85)	0.9811	6.68
Encoder dilatih, laju 0,001	1	88.51	0.9513	11.49
Proposal apa adanya, laju 0,001 seragam	3	93.57 (1.75)	0.9824	6.50

WavLM Large, 300 juta parameter, swa-selia

Perlakuan encoder	n	Akurasi	AUC	EER
Encoder dibekukan	3	98.62 (0.64)	0.9992	1.41
Encoder dilatih, laju wajar per model	3	97.30 (1.71)	0.9959	2.70
Encoder dilatih, laju 0,001	1	80.06	0.8963	19.94
Proposal apa adanya, laju 0,001 seragam	3	63.73 (5.86)	0.7205	36.31

HuBERT Large, 300 juta parameter, swa-selia

Perlakuan encoder	n	Akurasi	AUC	EER
Encoder dibekukan	3	94.67 (1.12)	0.9907	5.33
Encoder dilatih, laju wajar per model	3	97.49 (1.33)	0.9970	2.51
Encoder dilatih, laju 0,001	1	43.66	0.4837	55.97
Proposal apa adanya, laju 0,001 seragam	3	52.14 (8.08)	0.5605	48.22



Gambar 7. Perlakuan encoder terbaik berbeda menurut arsitektur. Tiga batang pertama tiap kelompok memakai paket rekayasa yang sama dan hanya berbeda pada perlakuan encoder. Garis merah menandai tingkat tebakan acak.

Dua pola yang berbeda perlu dipisahkan. Pola pertama konsisten pada seluruh arsitektur yang diuji, yaitu bahwa besaran learning rate harus disesuaikan dengan encodernya. Laju 0,001 yang ditetapkan proposal menghancurkan kedua model swa-selia berukuran 300 juta parameter sampai mendekati tebakan acak, yaitu 63.73 persen (5.86) pada WavLM Large dan 52.14 persen (8.08) pada HuBERT Large, sementara laju yang sama justru membantu AST yang berukuran 86 juta parameter. Pola ini terlihat pada dua model yang tujuan dan korpus pra-pelatihannya berbeda, sehingga cukup kuat untuk dilaporkan.

Pola kedua tidak konsisten, dan penulis semula keliru menggeneralisasikannya. Bila learning rate sudah wajar, selisih antara melatih encoder dan membekukannya adalah AST +4.23 poin, WavLM Large -1.32 poin, HuBERT Large +2.82 poin. Dugaan awal bahwa model swa-selia berukuran besar sebaiknya dibekukan karena representasinya sudah selaras dengan tugas ternyata tidak bertahan. HuBERT Large berukuran sama dan sama-sama swa-selia, namun berperilaku seperti AST dan bukan seperti WavLM. Yang tersisa dari dugaan itu hanyalah pengamatan bahwa WavLM Large merupakan pengecualian, dan penelitian ini tidak memiliki bukti yang cukup untuk menjelaskan mengapa. Pra-pelatihan WavLM yang menyertakan denoising merupakan kandidat penjelasan, namun itu tetap dugaan yang belum diuji.

Selisih-selisih itu harus dibaca bersama sebarannya, dan kolom n pada tabel menunjukkan berapa inisialisasi acak yang menopang tiap sel. Sel AST yang encodernya dilatih dijalankan dengan tiga inisialisasi dan menghasilkan 91,64 sampai 95,31 persen, yaitu rentang 3,67 poin persentase dengan simpangan baku 1,85. Rentang sebesar itu lebih lebar daripada selisih antara kedua metodologi pada arsitektur tersebut, sehingga perbandingan berbasis satu inisialisasi di sini tidak dapat menyimpulkan apa pun. Beberapa sel lain dalam tabel masih bersandar pada satu inisialisasi, dan kesimpulan mengenai sel-sel tersebut karena itu bersifat sementara.

Temuan ini menempatkan kedua metodologi pada posisi yang setara. Proposal menyeragamkan learning rate 0,001 untuk seluruh arsitektur, yang kebetulan tepat untuk AST dan menghancurkan WavLM Large. Konfigurasi rekayasa dalam penelitian ini menyeragamkan pembekuan encoder untuk seluruh arsitektur, yang kebetulan tepat untuk WavLM Large dan merugikan AST. Keduanya melakukan kelas kesalahan yang sama, yaitu menetapkan satu keputusan secara seragam padahal arsitektur yang berbeda menuntut perlakuan yang berbeda. Kesimpulan yang jujur bukanlah bahwa satu metodologi mengalahkan yang lain, melainkan bahwa keputusan ini seharusnya dipilih per arsitektur menggunakan data validasi dan tidak ditetapkan di muka.

Satu dugaan tambahan sempat disusun dan kemudian gugur, dan kegugurannya dilaporkan di sini karena termasuk bagian dari temuan. Pada WavLM Large yang dilatih dengan laju 0,001 yang merusak itu, konfigurasi proposal jatuh ke 63.73 persen (5.86) sedangkan paket rekayasa dengan laju yang sama bertahan di 80.06 persen. Selisih itu semula ditafsirkan sebagai bukti bahwa early stopping, augmentasi penuh, dan agregasi berbobot antar lapisan berfungsi sebagai jaring pengaman terhadap pilihan learning rate yang buruk.

HuBERT Large membantah tafsir tersebut. Pada arsitektur itu, konfigurasi proposal dengan laju 0,001 mencapai 52.14 persen (8.08) sedangkan paket rekayasa dengan laju yang sama justru turun ke 43.66 persen dengan area under curve 0.4837, yaitu sedikit di bawah tebakan acak sehingga urutan skornya bahkan terbalik. Paket rekayasa tidak memberikan perlindungan apa pun di sini. Kesimpulan yang dapat dipertahankan karena itu lebih sempit daripada yang semula ditulis, yaitu bahwa perlindungan tersebut teramati pada WavLM Large dan tidak dapat digeneralisasi.

Hasil ini justru memperkuat pesan utama bagian ini dari arah yang lain. Learning rate yang tidak sesuai dengan encoder tidak dapat ditambal oleh perbaikan lain di dalam pipeline. Pada HuBERT Large, seluruh paket rekayasa yang di tempat lain menyumbang puluhan poin persentase tidak mampu mengangkat model dari tingkat tebakan ketika learning rate-nya keliru. Keputusan itu harus benar sejak awal.

3.11 Mana yang bertahan setelah ragam antar inisialisasi diukur

Seluruh selisih yang dilaporkan sejauh ini perlu diuji terhadap ragamnya sendiri. Tiap sel dijalankan dengan beberapa inisialisasi acak, lalu tiap perbandingan diuji dengan uji t Welch yang tidak mengandaikan ragam kedua kelompok sama. Perlu ditegaskan bahwa ukuran sampelnya kecil, yaitu paling banyak tiga inisialisasi per sel, sehingga uji ini berdaya rendah. Nilai p yang besar karena itu berarti belum terbukti berbeda, dan bukan terbukti sama.

Enam perbandingan diuji sekaligus, sehingga nilai p mentah tidak dapat dibaca apa adanya. Menguji enam hipotesis pada ambang 0,05 memberi peluang sekitar 26 persen untuk memperoleh setidaknya satu hasil yang tampak bermakna semata karena kebetulan. Koreksi Holm-Bonferroni karena itu diterapkan, dan keputusan diambil dari kolom p Holm.

Perbandingan	n	Rerata A	Rerata B	Selisih	p mentah	p Holm	Bacaan
AST, encoder dilatih lawan dibekukan	3/3	93.38	89.15	+4.23	0.1597	0.4792	belum terbukti berbeda
AST, encoder dilatih lawan proposal	3/3	93.38	93.57	-0.18	0.9064	0.9064	belum terbukti berbeda
WavLM, encoder dibekukan lawan dilatih	3/3	98.62	97.30	+1.32	0.3135	0.6269	belum terbukti berbeda
HuBERT, encoder dilatih lawan dibekukan	3/3	97.49	94.67	+2.82	0.0500	0.1998	belum terbukti berbeda
WavLM, rekayasa lawan proposal	3/3	98.62	63.73	+34.90	0.0087	0.0520	di garis batas
HuBERT, rekayasa lawan proposal	3/3	97.49	52.14	+45.34	0.0090	0.0520	di garis batas

Hasilnya terbelah bersih menjadi dua kelompok. Kelompok pertama adalah perbandingan antara konfigurasi proposal dan konfigurasi rekayasa pada kedua model swa-selia berukuran besar. Selisihnya berpuluh poin persentase, jauh melampaui simpangan baku antar inisialisasi yang berkisar satu sampai dua poin, sehingga kesimpulannya tidak mungkin dibalik oleh ragam. Kelompok kedua adalah perbandingan antara membekukan dan melatih encoder. Selisihnya berbilang poin dan berada pada orde yang sama dengan simpangan bakunya sendiri.

Untuk kelompok kedua, penelitian ini tidak berhak menyatakan bahwa satu perlakuan lebih baik daripada yang lain. Beberapa kesimpulan yang sempat ditarik lebih awal, ketika tiap sel baru dijalankan sekali, karena itu ditarik kembali. Pernyataan bahwa WavLM Large merupakan pengecualian yang sebaiknya dibekukan termasuk di antaranya, karena setelah tiga inisialisasi pada kedua sisi nilai p-nya 0,313.

Perbandingan pada HuBERT Large layak dibahas tersendiri karena berada tepat di garis batas. Melatih encoder unggul 2,82 poin persentase atas membekukannya dengan nilai p mentah 0,0500, yang setelah koreksi Holm menjadi 0,0999. Penulis memilih tidak menyatakannya sebagai temuan yang mapan. Nilai p yang berhenti persis di ambang, pada ukuran sampel tiga, merupakan keadaan yang paling mudah disalahtafsirkan, dan menyebutnya bermakna hanya karena kebetulan jatuh di sisi yang menguntungkan adalah bentuk pemilihan hasil yang justru dikritik oleh penelitian ini sendiri di bagian lain.

Kolom simpangan baku menyimpan pengamatan yang tidak terbaca dari rerata sama sekali, yaitu bahwa kestabilan hasil terhadap inisialisasi acak sangat berbeda antar arsitektur.

Arsitektur	Simpangan, encoder beku	Rentang, encoder beku	Simpangan, encoder dilatih	Rentang, encoder dilatih
AST	3.49	6.99	1.85	3.68
WavLM Large	0.64	1.19	1.71	3.12
HuBERT Large	1.12	2.02	1.33	2.39

Selisih kestabilan antar arsitektur mencapai satu orde besaran. Pada AST dengan encoder dibekukan, hasil ketiga inisialisasi terentang 85,66 sampai 92,65 persen, yaitu rentang 7 poin persentase yang lebih lebar daripada hampir semua selisih antar konfigurasi yang dibahas dalam penelitian ini. Pada HuBERT Large dengan perlakuan yang sama, rentangnya hanya 0,19 poin. Dua arsitektur yang dilaporkan berdampingan dalam satu tabel karena itu tidak memiliki bobot bukti yang setara, meskipun keduanya ditulis dengan jumlah angka desimal yang sama.

Konsekuensinya bagi penelitian ini cukup tajam. Seluruh tangga ablasi pada bagian 3.9 dijalankan pada AST, yaitu arsitektur yang paling tidak stabil di antara ketiganya. Selisih 16,91 poin untuk pembekuan encoder kemungkinan besar tetap bertahan karena jauh melampaui ragam tersebut, tetapi selisih 9,01 poin untuk early stopping dan terutama 4,78 poin untuk augmentasi penuh berada pada wilayah yang menuntut pengujian lebih lanjut sebelum dapat dinyatakan mantap.

Pada HuBERT Large, konfigurasi yang encodernya dibekukan juga jauh lebih dapat diulang daripada yang encodernya dilatih. Untuk pekerjaan yang harus dapat direproduksi oleh orang lain, sifat itu memiliki nilai tersendiri yang terpisah dari akurasi rerata, sehingga pemilihan di antara keduanya bukan semata soal angka mana yang lebih besar.

Pengamatan yang paling menjelaskan justru datang dari sel konfigurasi proposal pada kedua model swa-selia berukuran besar. Simpangan bakunya 5.86 poin persentase pada WavLM Large dan 8.08 pada HuBERT Large, yaitu beberapa kali lipat lebih besar daripada sel mana pun yang memakai learning rate yang sesuai. Pada HuBERT Large, ketiga inisialisasi menghasilkan 45,04 sampai 60,94 persen, yaitu rentang hampir 16 poin persentase.

Sebaran selebar itu konsisten dengan mekanisme yang diusulkan. Learning rate yang terlalu tinggi untuk encoder yang bersangkutan membuat pelatihan tidak stabil, sehingga tempat model berakhir sangat bergantung pada titik awalnya. Kegagalan yang diakibatkannya karena itu bukan hanya besar tetapi juga tidak terduga, dan itulah yang membuatnya berbahaya dalam praktik. Sebuah penelitian yang menjalankan konfigurasi ini sekali saja dapat memperoleh 60,94 persen dan menyimpulkan bahwa modelnya lemah, atau memperoleh 45,04 persen dan menyimpulkan bahwa modelnya tidak berfungsi, tanpa menyadari bahwa keduanya adalah konfigurasi yang sama.

Sebaran ini juga menjelaskan mengapa dua perbandingan dengan selisih terbesar dalam tabel di atas justru berhenti tepat di atas ambang setelah koreksi. Yang membatasi bukan kecilnya efek, melainkan liarnya kelompok pembanding.

Pengalaman ini sekaligus menjadi contoh konkret bagi anjuran yang diajukan penelitian ini sendiri, yaitu bahwa hasil sebaiknya dilaporkan beserta simpangan baku atas beberapa inisialisasi. Pada AST, rentang antar inisialisasi mencapai 3,67 poin persentase, yang lebih lebar daripada selisih antar metodologi. Bergantung pada inisialisasi mana yang kebetulan dilaporkan, penelitian yang sama dapat menyimpulkan bahwa rekayasa menang 2,75 poin atau kalah 0,92 poin. Kedua laporan itu akan terdengar sama meyakinkannya dan sama-sama tidak berdasar.

4. Usulan: Augmentasi Band-Gain

Diagnosis pada bagian 3.2 menunjukkan bahwa dua isyarat berbeda menempati pita frekuensi tinggi yang sama. Yang pertama adalah level energi, yang merupakan jejak kompresi dan harus dinetralkan. Yang kedua adalah struktur halus di dalam pita, yang merupakan jejak vocoder dan justru harus dipertahankan. Augmentasi yang lazim dipakai, seperti penapisan lolos bawah dan RawBoost, menghapus keduanya sekaligus.

Augmentasi band-gain yang diusulkan hanya mengalikan gain acak pada tiap pita di atas 3 kHz. Dengan demikian rasio energi antar pita menjadi tidak informatif terhadap label, sementara bentuk spektrum di dalam pita tetap utuh. Pengukuran memastikan sifat ini. Pada pita 6 sampai 7 kHz, band-gain menyisakan korelasi bentuk 0,89 terhadap sinyal asli dengan energi turun ke 41 persen, sedangkan penapisan lolos bawah menyisakan korelasi negatif 0,05 dengan energi nol persen.

Strategi augmentasi	Akurasi FoR	Recall TTS 2025-2026	Recall TTS 2019 non-MP3
Basis (noise, reverb, codec)	93.75 (5.15)	94.97 (5.34)	82.11 (22.95)
Basis ditambah RawBoost	98.50 (0.41)	87.64 (6.41)	60.67 (28.44)
Basis ditambah band-gain	97.12 (2.77)	93.50 (4.77)	92.15 (4.19)
Basis ditambah keduanya	97.46 (2.10)	93.67 (3.47)	85.04 (11.54)

Nes2Net-X, tiga seed per strategi, arsitektur dan data identik. Rerata diikuti simpangan baku dalam kurung.

Perbandingan tersebut menunjukkan bahwa RawBoost menaikkan akurasi pada dataset tetapi menurunkan kemampuan generalisasi, sedangkan band-gain menaikkan akurasi dengan penurunan generalisasi yang jauh lebih kecil dan bahkan memperbaiki recall pada sistem lama yang tidak dikompresi. Kombinasi keduanya memberi hasil terbaik pada beberapa sumbu sekaligus.

5. Keterbatasan

Beberapa keterbatasan perlu dinyatakan secara jujur. Pertama, sebagian besar konfigurasi hanya diulang dengan tiga inisialisasi acak, sedangkan variasi antar inisialisasi pada pengujian lintas generasi cukup besar, dalam beberapa kasus melebihi lima poin persentase. Kesimpulan mengenai urutan peringkat model karena itu bersifat indikatif.

Kedua, korelasi negatif antara akurasi in-domain dan kemampuan generalisasi dihitung dari tujuh model. Ukuran sampel sekecil itu tidak cukup untuk menyimpulkan besaran korelasinya. Yang menopang temuan ini bukan nilai korelasinya melainkan mekanismenya, yang terdokumentasi secara terpisah melalui audit dataset, eksperimen augmentasi terkontrol, dan pola kebutaan model terhadap sistem yang tidak dikompresi.

Ketiga, efek band-gain berbeda arah pada arsitektur yang berbeda. Penjelasan berdasarkan ruang perbaikan yang tersisa masuk akal namun disusun setelah melihat data, sehingga perlu pengujian pada arsitektur tambahan sebelum dapat dinyatakan sebagai mekanisme umum.

Keempat, sejumlah kesimpulan sementara dalam penelitian ini pernah keliru dan telah dikoreksi setelah pengukuran ulang. Riwayat koreksi tersebut sengaja dipertahankan dalam dokumentasi pendukung agar dapat ditelusuri.

6. Kesimpulan

Akurasi yang tinggi pada satu dataset tidak dengan sendirinya menunjukkan kemampuan mendeteksi suara sintesis. Pada Fake-or-Real, sebagian besar selisih angka yang dilaporkan dapat ditelusuri ke protokol pembagian data dan ke artefak kompresi yang berkorelasi dengan label. Kegagalan di bawah gangguan noise sebagian besar merupakan kegagalan kalibrasi ambang, bukan kegagalan pengenalan,

sehingga dapat dipulihkan tanpa mengubah model. Sistem text-to-speech komersial terbaru masih dapat dideteksi pada tingkat 97 sampai 99 persen dengan tingkat alarm palsu 5 persen, tetapi hanya oleh arsitektur dan strategi augmentasi tertentu, dan bukan oleh model yang menempati peringkat teratas pada dataset.

Pertanyaan apakah rekayasa metodologi dalam penelitian ini mengungguli rencana awalnya dijawab dengan tiga inisialisasi acak per sel dan uji yang dikoreksi untuk banding ganda. Jawabannya sebagian besar negatif, dan itu perlu dinyatakan terus terang. Pada AST, konfigurasi proposal mencapai 93.57 persen (1.75) sedangkan konfigurasi rekayasa dengan encoder yang dilatih mencapai 93.38 persen (1.85), yaitu selisih 0.18 poin yang tidak bermakna secara statistik. Perbandingan antara membekukan dan melatih encoder juga tidak terbukti berbeda pada ketiga arsitektur setelah koreksi Holm-Bonferroni. Selisih-selisih yang sempat tampak meyakinkan ketika tiap sel baru dijalankan sekali ternyata berada di dalam ragam antar inisialisasi.

Yang bertahan hanya satu, dan justru karena itu ia layak dipercaya. Besaran learning rate relatif terhadap ukuran dan jenis encoder adalah satu-satunya keputusan yang selisihnya berpuluh poin persentase, jauh melampaui ragam antar inisialisasi yang berkisar 0,1 sampai 3,5 poin. Learning rate seragam 0,001 kebetulan tepat untuk AST yang berukuran 86 juta parameter dan menghancurkan kedua model swa-selia berukuran 300 juta parameter sampai ke tingkat tebakan acak. Kekeliruan pada keputusan ini juga tidak dapat ditambal oleh perbaikan lain mana pun di dalam pipeline, sebagaimana ditunjukkan pada HuBERT Large.

Pesan praktis yang paling kokoh dari seluruh rangkaian percobaan ini adalah bahwa learning rate yang tidak sesuai dengan encoder tidak dapat ditambal oleh perbaikan lain di dalam pipeline. Pada HuBERT Large dengan laju 0,001, seluruh paket rekayasa yang di tempat lain menyumbang puluhan poin persentase tidak mampu mengangkat model dari tingkat tebakan acak. Perlindungan parsial yang sempat teramati pada WavLM Large ternyata tidak berulang, sehingga tidak dapat dinyatakan sebagai sifat umum paket tersebut.

Implikasi praktisnya adalah bahwa pemilihan model sebaiknya tidak didasarkan pada akurasi dataset tunggal, dan bahwa pelaporan hasil sebaiknya menyertakan spesifisitas pada korpus asing serta simpangan baku atas beberapa inisialisasi.

Anjuran terakhir itu bukan formalitas yang dipinjam dari literatur. Penelitian ini sendiri hampir melaporkan sejumlah kesimpulan yang keliru karena mengabaikannya. Pada AST dengan encoder dibekukan, tiga inisialisasi menghasilkan 85,66 sampai 92,65 persen, yaitu rentang yang lebih lebar daripada hampir semua selisih antar konfigurasi yang dibahas di sini. Bergantung pada inisialisasi mana yang kebetulan dijalankan lebih dahulu, laporan yang sama dapat menyimpulkan bahwa rekayasa unggul beberapa poin atau tertinggal beberapa poin, dan kedua versi akan terbaca sama meyakinkannya. Praktik melaporkan satu angka dari satu inisialisasi karena itu bukan sekadar kurang teliti, melainkan cukup untuk membalik arah kesimpulan sebuah penelitian.