

AMBANG KEPUTUSAN, **BUKAN ARSITEKTUR**

Audit ulang deteksi deepfake audio pada dataset Fake-or-Real: apa yang sebenarnya diukur, apa yang tidak bertahan, dan apa yang ditemukan di luar rencana.

Gusti Ayu Putu Kesari Purnama Yani

Magister Sistem Informasi, ITB STIKOM Bali

Pembimbing

Dr. Dandy Pramana Hostiadi, S.Kom., M.T.

Dr. Gede Angga Pradipta, S.T., M.Eng.

Rumusan masalah yang harus dijawab

Kalimat berikut dikutip apa adanya dari proposal, bagian 1.2.

Bagaimana kinerja arsitektur deep learning Wav2Vec2, Audio Spectrogram Transformer, HuBERT Large, dan CNN-LSTM dalam mengklasifikasikan suara asli dan deepfake dalam kondisi dengan gangguan noise?

Untuk menjawabnya dengan jujur, tiga hal dikerjakan sekaligus, dan urutannya menentukan. Dataset diaudit lebih dahulu sebelum satu model pun dilatih. Kegagalan dipisahkan menjadi kegagalan mengenali dan kegagalan memutuskan. Setiap konfigurasi dijalankan berkali-kali sehingga selisihnya dapat dibandingkan dengan ragamnya sendiri.

Jawabannya, sebelum pembuktiannya

Tiga kalimat ini adalah keseluruhan temuan. Sisa presentasi hanya menunjukkan dari mana ketiganya berasal.

- 1 Yang dipelajari model sebagian bukan jejak sintesis, melainkan riwayat berkas.**
90,7% sampel palsu di data latih berasal dari MP3, dan 0,0% di data uji.
- 2 Kegagalan di bawah noise sebagian besar kegagalan kalibrasi, bukan pengenalan.**
Daya pisah bertahan sementara letak ambangnya bergeser.
- 3 Sebagian besar selisih antar arsitektur lebih kecil daripada ragam antar inisialisasi.**
Dari enam perbandingan utama, hanya dua yang bertahan setelah diuji.

01

Sebelum melatih apa pun

Dataset diperiksa lebih dahulu. Bagian ini berisi temuan yang tidak memerlukan satu pun model, tidak memiliki ragam antar inisialisasi, dan karena itu bertahan tanpa syarat.

Yang diperiksa sebelum pelatihan dimulai

Seluruh 17.870 berkas dibaca satu per satu. Hasilnya deterministik dan dapat diulang siapa pun dalam hitungan menit.

17.870 berkas

seluruhnya 16 kHz mono, durasi tepat 2,000 detik

0 duplikat

tidak ada berkas identik yang melintasi partisi

0,50001 AUC

pintasan keheningan awal, praktis tidak ada


0,698 AUC

fitur trivial terkuat, yaitu tingkat energi rata-rata

Partisi resminya 78,1 / 15,8 / 6,1 persen, bukan 60/20/20 seperti rencana proposal. Mencapai 60/20/20 menuntut penggabungan ulang seluruh data, dan itu menghancurkan pemisahan domain yang sengaja dirancang pembuat dataset.

Temuan pertama: riwayat kompresi, bukan jejak sintesis

Dihitung langsung dari nama berkas dan label. Tanpa model, tanpa keacakan, sehingga tidak memerlukan pengujian statistik.



Akibatnya

Model yang mempelajari jejak MP3 akan memperoleh isyarat hampir sempurna pada dua partisi pertama, lalu kehilangan isyarat itu seluruhnya pada partisi ketiga.

Terukur pada energi di atas 6 kHz. Palsu turunan MP3 berselisih 4,18 kali terhadap asli, sedangkan palsu yang bukan turunan MP3 hanya 1,17 kali.

Ini temuan terkuat penelitian ini justru karena ia tidak bergantung pada model, pelatihan, maupun keberuntungan inisialisasi.


02

Menjawab pertanyaan noise

Rumusan masalah menanyakan kinerja di bawah gangguan derau. Jawabannya ternyata bukan tentang seberapa jauh kinerja turun, melainkan tentang bagian mana yang turun.

Akurasi runtuh, daya pisah tidak

WavLM diuji pada derau DEMAND, korpus yang tidak pernah dipakai saat pelatihan. Sumbu kiri akurasi, sumbu kanan AUC.



Model masih memisahkan kedua kelas hampir sempurna. Yang salah hanyalah letak garis keputusannya, dan itu dapat diperbaiki tanpa melatih ulang apa pun.

Selisih yang semula dikira soal protokol

Selisih 49,9 poin yang sempat dilaporkan ternyata memuat tiga sebab yang terpisah. Yang selama ini dianggap utama justru menyumbang paling sedikit.



Efek protokolnya sendiri belum terbukti, yaitu 6,92 poin dengan p sebesar 0,0822 pada uji Welch. Yang tersisa dari temuan pembuka ini adalah peringatan yang berbeda dari yang semula ditulis: sebab utamanya kalibrasi ambang, bukan pembagian data.

Jawaban atas rumusan masalah

Dinyatakan sebagai kalimat yang dapat diuji ulang orang lain.

Di bawah gangguan derau lingkungan, keempat arsitektur tidak kehilangan kemampuan membedakan suara asli dari suara buatan sebesar yang tampak dari angka akurasi. Sebagian besar penurunan akurasi berasal dari bergesernya letak ambang keputusan, bukan dari hilangnya daya pisah. Konsekuensi praktisnya, perbaikan yang tepat adalah mengkalibrasi ulang ambang, bukan melatih ulang model.

Pernyataan ini berlaku pada arsitektur yang AUC-nya memang bertahan. CNN-LSTM gagal dengan cara yang berbeda dan harus dinyatakan terpisah: AUC-nya sendiri jatuh ke 0,605, sehingga yang hilang memang daya pisahnya, bukan ambangnya.


03

Perbandingan arsitektur

Bagian yang menjadi judul penelitian. Hasilnya perlu dinyatakan dengan hati-hati, karena sebagian besar selisih di sini tidak lebih besar daripada ragam antar inisialisasi acak.

Hasil pada partisi resmi


Rerata beserta simpangan baku atas beberapa inisialisasi acak, pada ambang prior-matched. Batang galat adalah simpangan bakunya.



Peringkatnya tampak jelas. Bagian berikutnya menunjukkan mengapa sebagian besar jarak pada grafik ini belum boleh dibaca sebagai perbedaan.

Ragam antar inisialisasi menelan sebagian besar selisih


Konfigurasi yang sama persis, dijalankan ulang hanya dengan angka awal acak yang berbeda. Titik adalah satu pelatihan, belah ketupat reratanya.



Nes2Net dengan pengaturan identik memberi 87,87 dan 97,43 persen. Selisih 9,56 poin yang satu-satunya sebabnya adalah angka pertama di dalam pembangkit acak. Melaporkan satu angka tunggal pada konfigurasi semacam ini menyesatkan, apa pun metodenya.

Yang bertahan: laju belajar harus menyesuaikan encoder

Satu-satunya temuan kuantitatif yang lolos pengujian dengan selisih berpuluh poin. Diuji dengan t Welch dan koreksi Holm-Bonferroni.



Satu laju belajar seragam 0,001 berjalan wajar pada AST yang 86 juta parameter, tetapi menjatuhkan kedua model 300 juta parameter ke tingkat tebakan koin. Keputusan ini harus ditetapkan per arsitektur, bukan diseragamkan di muka.

04

Yang tidak bertahan

Tiga belas pernyataan sempat ditulis lalu gugur setelah diuji ulang. Mencantumkannya bukan formalitas, melainkan satu-satunya cara membuat sisa hasilnya dapat dipercaya.

Klaim yang ditarik dan alasannya

Enam yang paling berpengaruh terhadap kesimpulan. Tujuh sisanya tercatat pada berkas hasil di repositori.

KLAIM	ALASAN PENARIKAN
Protokol pembagian data menentukan hasil, sekitar 50 poin	Menggabungkan tiga sebab. Protokol hanya 6,92 poin, dan itu pun $p = 0,0822$
Korelasi -0,542 antara akurasi FoR dan deteksi TTS mutakhir	Dihitung tanpa merata-ratakan seed. Setelah dikoreksi menjadi -0,048 dengan $p = 0,895$
Band-gain memperbaiki generalisasi sebesar sepuluh poin	Dua belas perbandingan diuji, seluruhnya memberi p Holm 1,0000
Encoder yang dibekukan lebih baik daripada yang dilatih	Arahnya berbeda antar arsitektur, tidak satu pun lolos koreksi Holm
Nilai rekayasa +37,59 poin persentase	Artefak dari baseline yang lumpuh karena bug, bukan hasil rekayasa
Sebagian besar hasil terbitan pada FoR memakai split acak	Terbantah. Satu penelitian terverifikasi memakai partisi resmi speaker-disjoint

Kekeliruan terbesar, dan cara ia ketahuan

Bendera untuk melatih encoder tidak pernah benar-benar bekerja. Log mencetak encoder DILATIH, padahal tidak satu pun gradien sampai ke sana.

0 dari 211

parameter encoder yang menerima gradien sebelum diperbaiki

210 dari 211

sesudah satu atribut diperbaiki

7 kekeliruan

seluruhnya berjenis sama dan gagal tanpa pesan error

Bug ini tidak ditemukan lewat pembacaan kode, melainkan lewat tangga ablasi yang kebetulan menempatkan dua konfigurasi berbeda secara berdampingan. Keduanya menghasilkan skor identik sampai empat desimal, dan dua konfigurasi yang berbeda tidak mungkin identik bitwise kecuali keduanya sebenarnya sama.

Sebagai tanggapan, dipasang pemeriksa otomatis yang menolak menyusun laporan bila ada kelompok run memuat lebih dari satu konfigurasi pelatihan tanpa alasan tercatat. Pengaman struktural, bukan kewaspadaan.


05

Di luar rencana proposal

Empat hal yang tidak diminta proposal, muncul dari pengukuran sendiri, dan menyentuh cara bidang ini melaporkan hasilnya.

Model publik terkemuka runtuh di luar domainnya

Nes2Net-X, EER 1,49 persen pada ASVspoof 2021 DF, diuji zero-shot tanpa adaptasi apa pun.



AUC di bawah lima puluh persen berarti pengurutannya terbalik, bukan sekadar buruk. Metrik EER di dalam domain secara struktural tidak dapat menangkap mode kegagalan ini, dan itu celah evaluasi yang nyata.

Empat hal yang ditemukan di luar proposal

Seluruhnya berasal dari pengukuran pada mesin sendiri, bukan dari literatur.

TEMUAN	APA YANG DITAMBAHKAN
Audit provenance codec pada Fake-or-Real	Ketidakseimbangan riwayat kompresi yang sudah ada di dalam dataset apa adanya, belum terdokumentasi sebelumnya
Pemisahan kegagalan pengenalan dan kegagalan kalibrasi	Bidang ini melaporkan EER yang bebas ambang, sehingga buta terhadap mode kegagalan yang dominan di pemakaian nyata
Pengujian lintas generasi text-to-speech	Empat belas sistem dari empat generasi, diukur pada spesifisitas 95 persen yang disamakan sehingga adil
Pelaporan ragam antar inisialisasi	Ketiga penelitian pembanding pada FoR tidak mencantumkan simpangan baku sama sekali

Posisi terhadap arsitektur mutakhir

Empat arsitektur pada judul mewakili generasi 2020 sampai 2022. Perkembangan sesudahnya bergerak ke bagian belakang model, bukan ke penyari depannya.

PENDEKATAN	TAHUN	CATATAN
RawNet2, AASIST	2021-2022	Bagian belakang berbasis graf, masih menjadi acuan pembanding
wav2vec 2.0 disetel ulang	2022	Menetapkan pola penyari depan swa-selia yang kini lazim
Nes2Net-X	2025	Bagian belakang bersarang 511 ribu parameter, EER 1,49 persen pada ASVspoof 2021 DF
XLSR-Mamba, SLS, TCM	2024-2025	Varian bagian belakang, selisih antar keduanya berbilang persepuluh poin

Nes2Net-X ikut diuji dalam penelitian ini, dan justru pada model itu keruntuhan lintas domain paling terlihat. Kebaruan arsitektur tidak menyelesaikan masalah kalibrasi.

Kesimpulan

Dua temuan bertahan, dan keduanya perlu dinyatakan terus terang.

Kalibrasi ambang keputusan

Sebagian besar kegagalan yang terlihat sebagai runtuhnya kemampuan sebenarnya adalah bergesernya letak ambang. Berlaku pada dua percobaan yang tidak berhubungan.

Besaran laju belajar relatif terhadap encoder

Selisih berpuluh poin dengan p Holm 0,0002 pada dua model swa-selia berukuran besar, diuji atas lima inisialisasi.

Keduanya tidak menyangkut pilihan arsitektur sama sekali, padahal judul penelitian ini menyangkut perbandingan arsitektur. Hal itu dinyatakan apa adanya, bukan disembunyikan.

Yang masih harus dikerjakan

Diurutkan menurut seberapa besar pengaruhnya terhadap kesimpulan.

PEKERJAAN

MENGAPA PENTING

Menyamakan kapasitas penyari depan swa-selia

Wav2Vec2 Base 95 juta dibandingkan dengan HuBERT Large 300 juta, sehingga arsitektur dan kapasitas masih tercampur

Mengukur ulang pintasan keheningan pada varian for-norm

Nama berkas menunjukkan keheningan sudah dibuang saat for-2sec dibuat, jadi hasil nol pada varian ini belum tentu berlaku umum

Menambah inisialisasi pada sel yang masih tiga

Pada n sebesar tiga, selang kepercayaan simpangan bakunya sendiri membentang setengah sampai tiga kali lipat

Kalibrasi induktif yang tidak memerlukan seluruh skor uji

Ambang prior-matched bersifat transduktif, sehingga belum siap dipakai pada deteksi satu per satu

Terima kasih

Seluruh angka pada presentasi ini dihitung ulang dari berkas hasil setiap kali dokumen dibangun, sehingga tidak mungkin ada angka usang. Kode, skor 159 pelatihan, naskah lengkap, dan daftar klaim yang ditarik tersedia terbuka.

github.com/Tristan-tech-ai/general-AI